

O teto da autocorreção: o que o validador não vê no SQL Bot multiagente do LinkedIn

Carlos Ulisses Flores

Trabalho apresentado para o *course* MIT 509 – AI Engineering da American Global Tech University - AGTU.

Prof. Dr. Rodrigo Bernardino

9 de novembro de 2026

Resumo

O estudo de caso analisa o SQL Bot, assistente multiagente que converte perguntas em linguagem natural em consultas SQL sobre o armazém de dados do LinkedIn. Objetivou-se avaliar a solução e explicar por que a taxa de compilação se aproxima de 100% enquanto a fração avaliada como correta ou quase correta permanece perto de metade. A metodologia combinou análise documental de três fontes primárias, literatura e decomposição analítica verificada em repositório. Na ablação publicada, a configuração com o corretor de consultas, sem o agente pesquisador, eleva a compilação de 76% para 95% mantendo em 47% as consultas com nota 4 ou 5 numa escala de 1 a 5, enquanto componentes do grafo de conhecimento elevam essa fração de 9% para 49%. Propõe-se o teto de autocorreção: um corretor acionado apenas pelos sinais do validador não ultrapassa 100% menos a fração de perguntas cuja consulta inicial errada esse validador não sinaliza. Supondo o mesmo conjunto de perguntas nas duas medidas, a fração de perguntas cuja consulta compila sem nota 4 ou 5 fica entre 48% e 53% com o corretor, ante 29% a 53% sem ele, compatível com a conversão de erro visível em erro silencioso, mas que não a demonstra. Conclui-se que a arquitetura serve à democratização do acesso a dados e que elevar o teto depende de reduzir o erro silencioso, por contexto governado, validação semântica sem executar a consulta em produção e interação com o usuário, pois mais rodadas não alcançam o erro que não é sinalizado.

Palavras-chave: agentes de IA; sistemas multiagentes; text-to-SQL; autocorreção; validação; governança de dados.

Abstract

This case study analyzes SQL Bot, a multi-agent assistant that turns natural-language questions into SQL queries over LinkedIn's data warehouse. It aimed to assess the solution and to explain why query compilation approaches its maximum while the share rated correct or almost correct stays near half. The method combined a documentary analysis of three primary sources, the literature and an analytical decomposition verified in a repository. In the published ablation, the query fixer, added without the researcher agent, raises compilation from 76% to 95% keeping at 47% the queries rated 4 or 5 on a 1-to-5 scale, while knowledge-graph components raise that share from 9% to 49%. The study proposes the self-correction ceiling: a fixer triggered only by the validator's signals cannot exceed 100% minus the share of questions whose initially incorrect query that validator does not flag. Assuming the same set of questions in both measures, the share of questions whose query compiles without a 4 or 5 lies between 48% and 53% with the fixer, against 29% to 53% without it, a pattern compatible with visible errors being turned into silent ones but that does not demonstrate it. It concludes that the architecture serves data democratization and that raising the ceiling depends on reducing the errors the validator cannot see, through governed context, semantic validation without running the query in production and user interaction, because more correction rounds cannot reach errors that leave the loop unflagged.

Keywords: AI agents; multi-agent systems; text-to-SQL; self-correction; validation; data governance.

1 Introdução

Em empresas de tecnologia, especialistas em dados gastam parte relevante do tempo ajudando colegas a encontrar os dados de que precisam, e esse gargalo atrasa decisões de áreas que dependem de números (Chen et al., 2024). A conversão de perguntas em linguagem natural em SQL (*text-to-SQL*) parece resolvida nos conjuntos acadêmicos de referência: no BIRD, a acurácia de execução subiu de 40% em 2023 para 76% em 2025, segundo o levantamento da própria equipe do caso (Chen et al., 2025). O cenário corporativo, contudo, é outro: esquemas com milhares de tabelas, nomes ambíguos e jargão interno derrubam os mesmos modelos (Floratou et al., 2024), e, no LinkedIn, as tabelas somam milhões (Chen et al., 2024). No Spider 2.0, construído sobre fluxos reais de empresas, o agente proposto pelos autores, sobre o modelo de raciocínio o1-preview, resolveu 21,3% das tarefas na publicação (Lei et al., 2025); no placar público consultado em 7 de novembro de 2026, entradas enviadas alcançavam 96,7% na variante Snow e 76,2% na Lite (Spider 2.0, s.d.). Esses placares usam a equivalência de resultados num banco de teste como aproximação da correção da consulta, critério que não garante, por si só, o atendimento à intenção de quem pergunta em produção. Este estudo argumenta que, nesse regime, a autocorreção guiada por validador tem um teto fixado pelo que o validador não enxerga e que, no SQL Bot, os totais publicados situam em cerca de metade das perguntas a fração de consultas que compilam sem nota 4 ou mais (correta ou quase correta).

O LinkedIn enfrentou esse problema com o SQL Bot, assistente integrado à plataforma interna de ciência de dados DARWIN que encontra tabelas, escreve consultas e corrige erros sob as permissões de cada funcionário, construído como sistema multiagente sobre LangChain e LangGraph (Chen et al., 2024). O objetivo declarado é a democratização do acesso a dados: permitir que funcionários sem domínio profundo de SQL obtenham respostas sem depender da

equipe de dados. Os resultados relatados incluem adoção cinco a dez vezes maior após a integração ao editor de consultas, 80% das sessões concentradas no botão “Fix with AI”, mais de 300 usuários ativos por semana e, numa pesquisa, cerca de 95% dos usuários avaliaram as consultas como “Passes” (aproveitáveis com algumas modificações) ou acima (Chen et al., 2024, 2025).

A questão-problema deste estudo é a seguinte: por que um sistema que compila 96% das consultas entrega como corretas ou quase corretas apenas 48% das perguntas, e o que a arquitetura de agentes pode ou não pode fazer a respeito? A justificativa é dupla. Primeiro, o caso distingue-se entre os casos empresariais examinados por publicar ablação componente a componente de um sistema em produção (Chen et al., 2025). Segundo, a autocorreção é um dos mecanismos agênticos mais difundidos e dos menos compreendidos: a autocorreção intrínseca de modelos de linguagem não apresenta ganhos confiáveis em tarefas gerais nas avaliações examinadas, embora haja exceções, e sinais externos confiáveis ou treinamento específico podem torná-la eficaz (J. Huang et al., 2024; Kamoi et al., 2024).

O objetivo geral é avaliar a solução diante do desafio, dos objetivos e dos resultados. Os objetivos específicos são: (a) descrever a arquitetura documentada, separando fato publicado de proposta do autor; (b) analisar geração aumentada por recuperação (*retrieval-augmented generation*, RAG), orquestração, segurança, governança e avaliação à luz da engenharia de IA (Acharya et al., 2025); e (c) formalizar o limite da autocorreção e confrontá-lo com a ablação publicada.

A metodologia é qualitativa e documental, com um componente analítico verificável. Examinaram-se o artigo de engenharia do LinkedIn, o *preprint* da mesma equipe com a ablação, versão no arXiv do trabalho aceito como pôster num *workshop* da KDD 2025, com revisão

simples-cega (Workshop on Agentic AI for Enterprise, 2025), e a palestra técnica no Trino Summit 2024, além de literatura revisada por pares sobre avaliação, autocorreção e segurança. A decomposição proposta foi implementada e testada contra simulação de eventos em repositório público (Flores, 2026). O artigo segue com o caso selecionado (seção 2.1), a análise técnica e arquitetural (seção 2.2), a discussão com a proposição do teto (seção 2.3) e as considerações finais.

2 Desenvolvimento

2.1 Caso Selecionado

O caso é documentado por três fontes primárias da mesma equipe de engenharia, de natureza e grau de evidência distintos. O artigo de engenharia descreve o sistema, as estratégias e as lições, com números de adoção e satisfação (Chen et al., 2024). O *preprint*, apresentado no Workshop on Agentic AI for Enterprise da conferência KDD 2025, detalha a implementação e publica a única ablação do sistema, com uma execução por configuração (Chen et al., 2025). A palestra técnica acrescenta detalhes de validação ditos de viva voz (Ahlawat et al., 2024; Trino, 2024). Entre as fontes examinadas neste estudo, não se identificou replicação independente; a única crítica independente identificada, uma revisão aberta, aponta o conjunto de avaliação interno como limite (Ghosh, 2025). A Tabela 1 separa o que cada evidência mede do que ela não permite concluir.

Três descobertas estruturam o caso. A primeira é que a dificuldade não se limita a gerar SQL: achar a fonte autoritativa entre milhões de tabelas é gargalo central; para enfrentá-lo, a equipe reduz o universo a alguns milhares pela popularidade de acesso, infere os conjuntos de dados padrão de cada usuário pelo organograma e aplica análise de componentes independentes ao histórico de acesso (Chen et al., 2024). A segunda é que a experiência de uso foi central para a adoção, segundo a equipe, embora as fontes não isolem sua contribuição diante da acurácia: disponível na plataforma de consultas desde julho de 2024 (Chen et al., 2025), a integração multiplicou o uso, e a função mais usada, a correção de consultas que falharam, foi fácil de construir (Chen et al., 2024). A terceira, menos citada, é que as duas medidas de qualidade divergem: cerca de 95% dos usuários consideraram as consultas aceitáveis, enquanto a revisão de especialistas na versão de produção, que conta respostas e não usuários, atribui nota 4 ou 5 a

53% delas, com “filtro incorreto” como problema mais comum, em 24% dos casos, e junção incorreta em apenas 4% (Chen et al., 2025).

Tabela 1

Evidências do caso: o que medem e o que não permitem concluir

Evidência	Como foi medida	O que não permite concluir
Adoção 5 a 10 vezes maior após a integração ao DARWIN; “Fix with AI” em 80% das sessões	Telemetria interna de uso	Se as respostas estavam corretas; sem contagem absoluta de sessões nem janela de observação
Mais de 300 usuários ativos por semana; 20% retornam na semana seguinte	Telemetria interna de uso	Valor para o usuário além do uso recorrente
Cerca de 95% “Passes” ou acima; cerca de 40% “Very Good” ou “Excellent”	Pesquisa com usuários, sem tamanho de amostra	Exatidão: mede acurácia percebida, sem validação independente
53% das 124 perguntas avaliadas com nota 4 ou 5, numa escala de 1 a 5	Revisão de especialistas na versão de produção	Desempenho fora das 10 áreas avaliadas
Ablação de 13 configurações; 48% com nota 4 ou mais na completa	Juiz gpt-4o em conjunto interno, uma execução por configuração	Estabilidade entre execuções; separar efeito da mudança e ruído

Fonte: Elaboração do autor, com base em Chen et al. (2024, 2025) e Trino (2024).

Nota. Noutro trecho da palestra, a adoção é descrita como 4 a 5 vezes maior (Trino, 2024, 17:49).

A divergência não indica erro das fontes: “Passes” é, entre os níveis publicados, o mais permissivo, e a pesquisa mede acurácia percebida, com categorias que admitem modificações e unidade de análise distinta da revisão de especialistas. Essa leitura, contudo, orienta a análise: as métricas são compatíveis com percepção favorável apesar da exatidão limitada, sem demonstrar a utilidade de consultas individualmente incorretas, e o risco desloca-se para o erro que o usuário

não percebe. Para os itens que as fontes não detalham, como controles de privacidade específicos do assistente, este estudo apresenta propostas fundamentadas, sinalizadas como tais.

O caso também se destaca entre os pares documentados. O QueryGPT da Uber relata cerca de 300 usuários ativos por dia e 78% de usuários com percepção de economia de tempo, sem publicar acurácia (Johnson et al., 2024). O Cortex Analyst da Snowflake relata mais de 90% de acurácia em casos de uso reais, numa avaliação inicialmente restrita a uma única visão (*view*) com dados previamente unidos, e, num conjunto interno de 150 perguntas, 51% para o GPT-4o com uma única instrução, com gabaritos múltiplos e correspondência leniente de colunas, critério não comparável à nota 4 ou mais do SQL Bot (R. Huang, 2024). A diferença de fundo é arquitetural: o Cortex Analyst responde sobre um modelo semântico declarado e reaproveita um repositório de consultas verificadas, pares de pergunta e SQL curados, quando a pergunta é semelhante (Snowflake, s.d.), enquanto o SQL Bot recupera tabelas físicas a partir de metadados. A diferença sugere compromissos distintos de curadoria e abrangência, cuja magnitude as fontes não comparam. Relatos chineses mostram um desenho com um degrau a mais: o ChatBI da FreeWheel valida esquema e sintaxe e, em seguida, avalia a correção de negócio da consulta, refazendo a seleção de tabelas quando ela não responde à pergunta, com acurácia acima de 90% em perguntas comuns sobre mais de 300 tabelas, sem métrica de erro silencioso publicada (Zhong & Cai, 2025). As fontes desses pares examinadas aqui não apresentam ablação por componente, o que torna o SQL Bot, entre eles, o caso com evidência mais granular para examinar a contribuição de cada agente.

2.2 Análise Técnica e Arquitetural

Desafio e objetivos. O desafio é responder perguntas de negócio num armazém com milhões de tabelas, em que descrições faltam ou estão incompletas, tabelas são substituídas a

cada poucos anos e a mesma pergunta, como a taxa de cliques de ontem, muda de significado conforme a área do funcionário (Chen et al., 2024). Os objetivos são reduzir o tempo dos especialistas gasto em consultas de terceiros e permitir acesso autônomo aos dados sob as permissões existentes. Os fatores de otimização declarados são produtividade, tempo de resposta e satisfação: a versão completa responde em menos de 60 segundos por pergunta, em média, e a equipe trata velocidade como requisito de implantação (Chen et al., 2025). As fontes não medem, porém, o tempo até uma consulta correta nem o custo total, e a latência do assistente não equivale a tempo poupado.

Solução, frameworks e provedores. O sistema foi implementado em LangChain, e o artigo de engenharia o descreve como multiagente sobre LangChain e LangGraph, este último um *framework* de orquestração de agentes como grafos de estado (Chen et al., 2024, 2025; LangChain, s.d.). Na avaliação do fluxo de escrita descrita no *preprint*, o agente pesquisador usa o gpt-4o-mini, mais rápido, e os demais modelos avaliados, inclusive a autorreflexão com que esse agente confere o próprio trabalho, usam o gpt-4o; na configuração de avaliação, todos os modelos, com temperatura zero, foram acessados pelo Azure OpenAI Service, e o gpt-3.5-turbo gera descrições de consultas de exemplo para indexação (Chen et al., 2025). O fluxo de informação segue coleta, processamento e apresentação: metadados do DataHub, registros de consultas, wikis e cadernos certificados alimentam um índice; a pergunta é classificada por intenção; e a resposta chega ao editor com explicação, tabelas usadas e verificações visíveis (Chen et al., 2024).

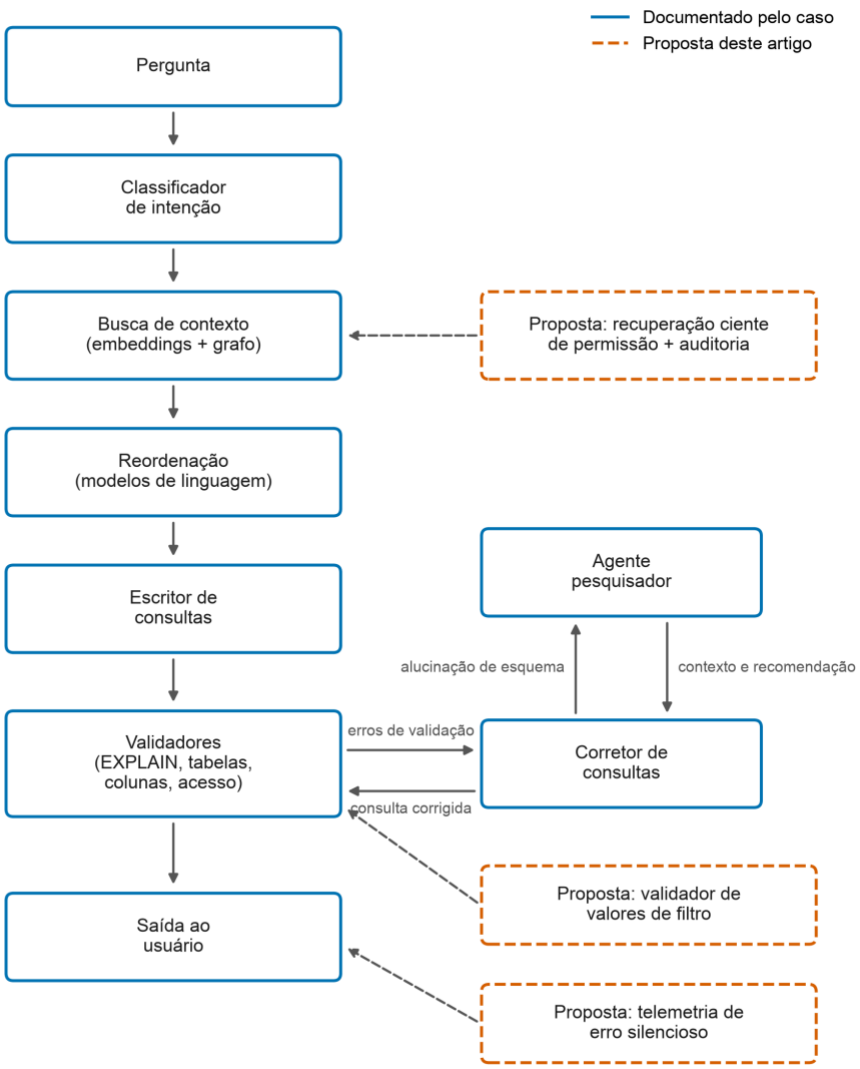
Geração aumentada por recuperação e grafo de conhecimento. A recuperação é o núcleo da solução. A recuperação reúne 20 tabelas de três fontes, a busca por *embeddings*, representações vetoriais do texto, as tabelas das consultas de exemplo recuperadas e as

mencionadas na pergunta (Chen et al., 2025), e um reordenador (*reranker*) baseado em modelo de linguagem seleciona as 7 que seguem para a escrita, usando um grafo de conhecimento com usuários, grupos de tabelas, tabelas e campos, cujos atributos vêm do DataHub, dos registros de consultas, do conhecimento de domínio informado pelos usuários e de descrições geradas por IA (Chen et al., 2024). Um esforço de certificação coletou descrições obrigatórias para centenas de tabelas importantes. A ablação mostra o peso desse componente: apenas com os esquemas das tabelas, 9% das consultas recebem nota 4 ou mais; com consultas de exemplo, grupos de tabelas e atributos de tabelas e colunas, 49% (Chen et al., 2025). Os componentes de contexto apresentam, portanto, os maiores ganhos observados nesta ablação, como antecipa a literatura que mostra que a seleção imperfeita de esquema exclui colunas necessárias à consulta (Maamari et al., 2024). Mais contexto, porém, não é melhor contexto por definição: na mesma ablação, acrescentar conhecimento de domínio e jargão fez a nota cair de 49% para 42%, numa única execução (Chen et al., 2025), diferença que não permite separar o efeito da mudança de contexto da variabilidade da avaliação.

Arquitetura de agentes e orquestração. Um classificador de intenção encaminha a pergunta para quatro fluxos: escrever consulta, encontrar dados, corrigir consulta e um agente de perguntas e respostas para o restante (Chen et al., 2024). A Figura 1 representa o fluxo de escrita, o mais complexo, e destaca em tracejado as propostas deste estudo.

Figura 1

Fluxo de escrita de consultas do SQL Bot, com componentes documentados e controles propostos



Fonte: Elaboração do autor, com base em Chen et al. (2024, 2025).

Nota. Traço cheio: componentes descritos pelas fontes. Traço tracejado: propostas do autor, não atribuídas à organização. Os fluxos de busca de dados, correção e perguntas gerais foram omitidos. O laço entre validador e corretor roda no máximo duas vezes e termina na aprovação ou no esgotamento das rodadas.

Na geração, o escritor planeja a consulta em etapas e guarda soluções parciais no estado interno, segundo o artigo de engenharia, embora, no *preprint*, o planejador tenha reduzido revocação e qualidade no conjunto de avaliação (Chen et al., 2024, 2025). Na validação, verifica-se a existência de tabelas e campos, com nomes extraídos por um modelo de linguagem, o que torna a validação predominantemente, e não estritamente, determinística, e executa-se o comando EXPLAIN do Trino em modo de validação, que confere sintaxe e nomes sem ler dados (Trino, 2024). Na correção, os erros voltam ao modelo pelo corretor de consultas (*query fixer*), no máximo duas vezes, e, quando há alucinação de esquema, um agente pesquisador (*researcher agent*) separado, munido de ferramentas para buscar tabelas e esquemas, devolve contexto atualizado e uma recomendação ao corretor, depois de conferir o próprio trabalho por autorreflexão (Ahlawat et al., 2024; Chen et al., 2024, 2025). Como esse agente só é acionado pelo sinal de alucinação do validador, a autorreflexão também depende desse sinal.

O padrão corresponde ao avaliador-otimizador: um componente gera, outro avalia, e a mensagem de erro da ferramenta volta como instrução de conserto. O desenho está mais próximo de um fluxo com laço do que de agentes autônomos; fluxos oferecem previsibilidade e consistência em tarefas bem definidas, enquanto agentes trocam latência e custo por flexibilidade (Schluntz & Zhang, 2024).

Privacidade, segurança e governança. O controle documentado é o de acesso: cada conjunto de dados tem lista de controle própria e, quando o usuário pertence a um grupo autorizado, o assistente fornece o código para usar as credenciais do grupo (Chen et al., 2024); segundo a palestra, a validação também verifica se o usuário pode ler as tabelas da consulta (Trino, 2024). O assistente não executa a consulta analítica final, que é submetida pelo próprio usuário, no editor, e a própria equipe registra não ter acesso aos dados para executar consultas

(Chen et al., 2025; Trino, 2024). As listas de acesso e a execução sob a identidade do usuário fazem o assistente respeitar as permissões existentes, condição necessária ao menor privilégio (Joint Task Force, 2020), embora as fontes não demonstrem que essas permissões sejam as mínimas necessárias. Esse desenho afasta a exploração automática descrita nos ataques de injeção que dependem de o sistema executar o SQL gerado (Pedro et al., 2025), classe registrada em vulnerabilidades de bibliotecas de agentes de dados, como o CVE-2023-36189 (National Institute of Standards and Technology [NIST], 2023), mas não elimina SQL malicioso apresentado ao usuário nem a injeção indireta pelo contexto. O argumento do teto vale também para segurança: os controles documentados verificam existência, sintaxe e autorização de acesso, mas não demonstram cobertura das demais políticas de uso dos dados, como finalidade e regras de negócio, e violações não representadas nesses controles podem permanecer sem sinalização durante o laço; as restrições de acesso devem ser impostas pelo motor de consulta, por mediação completa (Saltzer & Schroeder, 1975), com filtros de linha e máscaras de coluna, e não pelo corretor, enquanto restrições de finalidade e regras de negócio exigem políticas próprias, auditoria e validação semântica.

As fontes permitem identificar, como análise do autor, três pontos não tratados. Primeiro, instruções personalizadas e consultas de exemplo escritas por usuários entram no contexto de escrita e correção, e os cadernos são certificados pelos próprios usuários, sem aprovação descrita do dono do conjunto de dados (Chen et al., 2024, 2025), o que cria superfície de envenenamento do contexto, suscetível tanto a erro de curadoria quanto a manipulação deliberada, enquadrada como injeção indireta na lista OWASP (OWASP Gen AI Security Project, 2024). Segundo, a personalização perfila funcionários a partir de três meses de histórico de acesso a tabelas e da posição no organograma (Chen et al., 2025), sem que as fontes detalhem base jurídica,

transparência, retenção ou opção de não participação, aspectos que, no Brasil, seriam examinados pelos princípios da Lei Geral de Proteção de Dados (Lei n. 13.709, 2018). Terceiro, os K principais valores de campos categóricos entram no contexto do reordenador de campos (Chen et al., 2024), servido pelo Azure OpenAI Service ao menos na avaliação (Chen et al., 2025); a documentação vigente do serviço declara que entradas e saídas não são usadas para treinar modelos fundacionais de IA generativa sem permissão ou instrução do cliente (Microsoft, 2026), mas as fontes não detalham o acordo aplicável em 2024. Propõem-se aprovação da certificação pelo dono do conjunto de dados, recuperação ciente de permissão e trilha de auditoria por pergunta, alinhadas ao perfil de IA generativa do NIST (Autio et al., 2024). Como análise do autor, a representatividade decorre do próprio mecanismo: o recorte por popularidade de acesso e a certificação das tabelas mais usadas favorecem as áreas mais consultadas, e o conjunto de avaliação cobre 10 áreas escolhidas pela equipe, de modo que o desempenho em áreas pouco documentadas não é conhecido.

Monitoramento e avaliação. A avaliação combina revocação (*recall*) de tabelas e colunas na consulta gerada, em relação ao gabarito, medida que reflete o resultado do fluxo e não isola a recuperação inicial, taxa de alucinação, sintaxe e latência com avaliação humana e de um modelo de linguagem como juiz, num conjunto de mais de 130 perguntas de 10 áreas (Chen et al., 2024). Cerca de 60% das perguntas têm mais de uma resposta correta, e ignorá-las subestimava a revocação em 10% a 15%, sem que a fonte especifique se em termos relativos ou absolutos; especialistas revisam o gabarito a cada três meses, e a nota do juiz difere da humana em até um ponto em 75% dos casos (Chen et al., 2024). Em produção, o monitoramento documentado concentra-se em sinais de uso, como avaliações positivas e negativas na interface,

retenção semanal, sessões que levam código ao editor e análise de registros por intenção, sem medida da correção das respostas em produção (Chen et al., 2025; Trino, 2024).

Métricas e resultados. Na configuração completa, a revocação de tabelas é de 78%, a de colunas, de 56%, a compilação, de 96%, e a nota 4 ou mais, de 48% (Chen et al., 2025). Em relação à configuração com recuperação por *embeddings* e escritor, sem reordenadores, corretor e pesquisador (B.1), a alucinação de esquema caiu de 23% para 1%, e os erros de compilação, de 34% para 4% (Chen et al., 2025). A seção 2.3 decompõe esses números por configuração.

2.3 Discussão

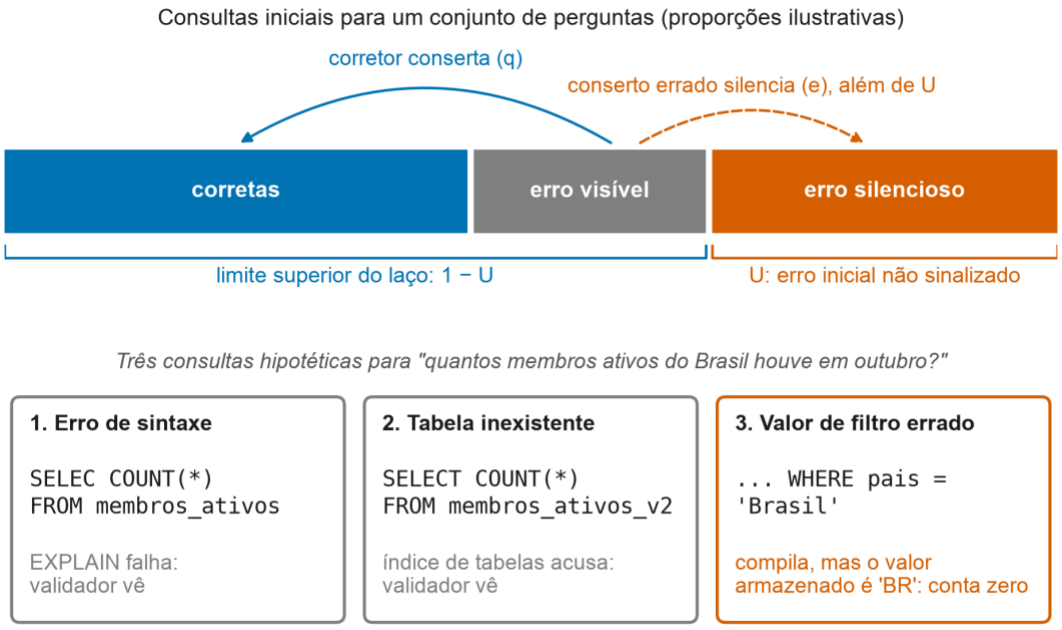
Os componentes de modelagem, isto é, reordenadores, corretor e agente pesquisador, elevaram a compilação de 66% para 96% e as chamadas de modelo por pergunta de 2,0 para 4,6, mas a nota 4 ou mais apenas de 46% para 48%; nas 13 configurações da ablação, a correlação de Pearson, calculada sobre os percentuais publicados, é de 0,27 entre compilação e nota e de 0,91 entre revocação de tabelas e nota, medida descritiva sobre configurações que compartilham componentes, não efeito causal (Chen et al., 2025; Flores, 2026). Os autores concluem que a correção semântica exige compreensão dos dados e que o grafo de conhecimento é a melhor alavanca (Chen et al., 2025). A observação é empírica. Propõe-se aqui uma explicação estrutural, construída em três passos: um exemplo, a proposição e o confronto com os dados.

Considere-se a pergunta hipotética “quantos membros ativos do Brasil houve em outubro?” e três consultas erradas para ela (Figura 2). A primeira tem erro de sintaxe, e o EXPLAIN falha; a segunda cita uma tabela inexistente, e o índice de tabelas acusa; a terceira compila e usa as tabelas certas, mas filtra o país pelo valor ‘Brasil’, quando o valor armazenado é ‘BR’, e conta zero membros. As duas primeiras são erros visíveis: o validador os sinaliza, e o

corretor pode agir. A terceira é um erro silencioso: nada a sinaliza, o corretor não é acionado e a resposta chega ao usuário. Repetir o laço não muda esse desfecho.

Figura 2

O que o validador vê: erro visível, erro silencioso e o limite do laço de correção



Fonte: Elaboração do autor.

Nota. Esquema conceitual; proporções e consultas são ilustrativas, não dados do caso.

Proposição do autor: o teto de autocorreção. Seja U a fração de perguntas cuja consulta inicial está errada e não é sinalizada pelo validador, saindo do laço. Se o corretor só é acionado pelos sinais do validador e as respostas não sinalizadas saem do laço, a acurácia final A satisfaz

$$A \leq 1 - U \tag{1}$$

com qualquer número de rodadas e qualquer eficácia do corretor. A desigualdade decorre da definição de U; o conteúdo do modelo está em identificar de que estágios vem U e como o corretor se aproxima do limite. No caso, A é aproximada pela nota 4 ou mais, aproximação imperfeita, porque a rubrica admite nessa nota um filtro de data incorreto (Chen et al., 2025). A fração invisível decompõe-se pelos estágios do *pipeline* (fluxo de processamento), com os parâmetros definidos na Tabela 2:

$$U = R(1 - G)(1 - d_{\mathrm{g}}) + (1 - R)(1 - G_0)(1 - d_{\mathrm{r}}) \tag{2}$$

O primeiro termo da Equação 2 cobre tabelas certas com escrita errada não sinalizada; o segundo, tabelas erradas com escrita errada não sinalizada.

Os parâmetros do corretor governam a aproximação ao teto da Equação 1. Se, a cada rodada, um erro sinalizado é consertado com probabilidade q, silenciado com probabilidade e ou permanece sinalizado, a probabilidade de conserto em até k rodadas é

$$P_{\mathrm{k}} = P_\infty \cdot [1 - (1 - q - e)^k] \tag{3}$$

em que $P_\infty = q / (q + e)$ é o patamar de P_{k} para k crescente, $q = c$ para erros de escrita e $q = r \cdot c$ para erros de recuperação, com c condicionado ao retorno, simplificação que admite o conserto dessa classe só após nova busca (Flores, 2026). A equação supõe taxas constantes por rodada, q, $e \geq 0$ e $q + e \leq 1$, com $P_\infty = 0$ quando $q + e = 0$. No modelo simplificado, sem corrupção de consultas corretas, sem silenciamento ($e = 0$) e com $q > 0$ em cada classe de erro sinalizado, mais rodadas aproximam a acurácia do teto sem elevá-lo; com $e > 0$, $P_\infty < 1$ e, havendo erros sinalizados, a acurácia converge para um patamar abaixo dele. No modelo, conserto e silenciamento são estados absorventes, e as probabilidades condicionam-se à permanência do erro no estado sinalizado. Com $r = 0$, o modelo não corrige erros de recuperação, embora o corretor real possa acertar com o contexto disponível.

Tabela 2

Parâmetros do modelo do teto de autocorreção

Símbolo	Significado	Estágio	Papel no teto
R	Recuperar todas as tabelas necessárias	Recuperação	Compõe U
G	Consulta correta, dadas as tabelas certas	Geração	Compõe U
G_0	Consulta correta, dadas tabelas erradas	Geração	Compõe U
d_g	Sinalização, dada consulta errada com tabelas certas	Validação	Compõe U
d_r	Sinalização, dada consulta errada com tabelas erradas	Validação	Compõe U
c	Consertar, numa rodada, um erro sinalizado ao seu alcance	Correção	Ritmo e patamar do conserto (Equação 3); não altera $1 - U$
q	Conserto por rodada na Equação 3 (c ou $r \cdot c$)	Correção	Ritmo e patamar do conserto; não altera $1 - U$
k	Número máximo de rodadas (2 no caso)	Correção	Oportunidades; não altera o teto
e	Silenciar, numa rodada, um erro sinalizado sem consertar	Correção	Converte visível em silencioso
r	Voltar à recuperação numa rodada (no caso, pelo pesquisador)	Correção	Pode permitir corrigir erro de recuperação

Fonte: Elaboração do autor.

Nota. R, G, G_0, d_g e d_r são probabilidades por pergunta; c, q, e e r, por rodada; k é contagem. "Tabelas erradas" é o complemento de R: não recuperar todas as tabelas necessárias, inclusive por recuperação incompleta. Com as definições condicionais, a Equação 2 decorre da probabilidade total. R refere-se a recuperar todas as tabelas necessárias à pergunta e não equivale à revocação média de tabelas publicada. A forma geral, com falsos positivos do validador que corrompem consultas corretas, risco documentado em reparos automáticos de SQL (Shen et al., 2026), a verificação por simulação e os valores ilustrativos estão no repositório (Flores, 2026).

A ideia geral não é nova: a melhoria por reamostragem é limitada pela taxa de falsos positivos do verificador, independentemente do orçamento computacional (Stroebl et al., 2024), a autoverificação é governada pela lacuna entre geração e verificação (Song et al., 2025), a estrutura de acerto inicial mais corrigido menos corrompido já está formalizada (Reitich, 2026; Yang et al., 2025) e a cobertura imperfeita é clássica em sistemas tolerantes a falhas (Arnold, 1973). A contribuição, até onde foi possível verificar, é especializar essa lógica ao *pipeline* multiagente de *text-to-SQL* com validador predominantemente determinístico, decompondo o teto por estágio, e confrontá-lo com uma ablação de produção.

O confronto exige separar o observado do não identificável. O corretor foi acrescentado sem o agente pesquisador, isto é, sem a busca ativa de novas tabelas, embora ainda receba os esquemas já recuperados e reordenados: a compilação sobe de 76% para 95%, e a nota 4 ou mais permanece em 47% (Chen et al., 2025). Os dados são agregados, sem pareamento por pergunta, e consultas que não compilam podem receber nota 4, pois o juiz recebe pergunta, resposta, gabarito e rubrica, sem execução descrita, e, no funcionamento do assistente, a equipe declara não ter acesso aos dados para executar consultas (Chen et al., 2025). Logo, a fração S de perguntas cuja consulta compila sem nota 4 ou mais não é observada; é apenas delimitada pelos totais, no sentido da identificação parcial (Manski, 2003). Supondo que compilação e nota se refiram ao mesmo conjunto de perguntas, com C a porcentagem de perguntas cuja consulta compila e Q a porcentagem com nota 4 ou mais, ambas em porcentagem, na escala de 0 a 100,

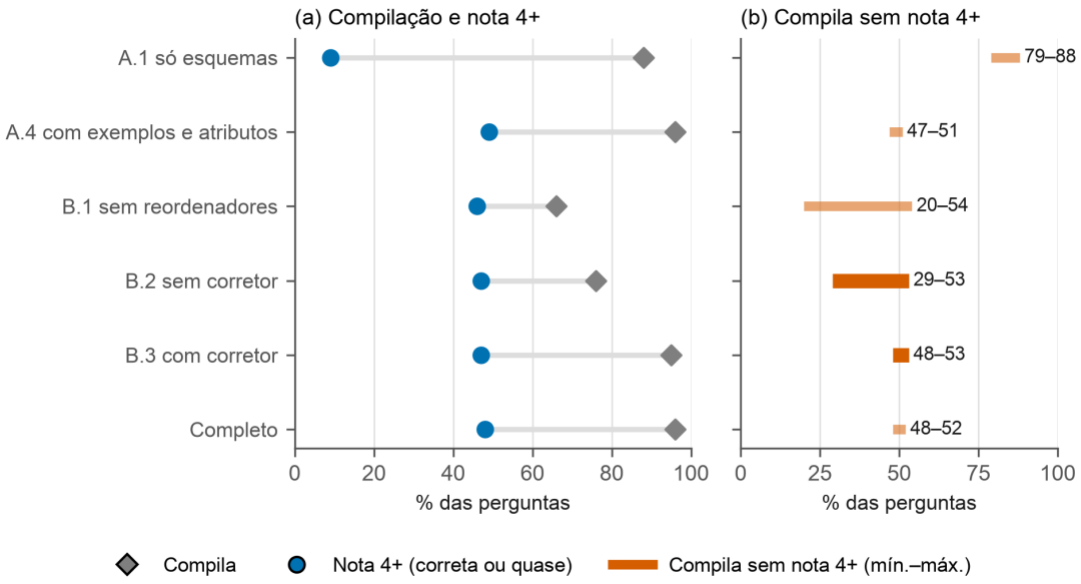
$$\max(0,\, C - Q) \leq S \leq \min(C,\, 100 - Q) \tag{4}$$

pois no máximo Q consultas que compilam têm nota 4 ou mais, e S não excede nem as que compilam nem as que não têm essa nota. As faixas tratam os inteiros publicados como exatos; com meio ponto de arredondamento em cada total, alargam-se para 28% a 53,5% e 47% a 53,5%

(Flores, 2026). As consultas de *U* compilam e saem do laço sem mudança; logo, a parcela de *U* que não recebe nota 4 ou mais está contida em *S*. A parcela de *U* que o juiz aprova não foi medida, e a nota 4 admite consulta quase correta; por isso, os totais delimitam *S*, mas não permitem usar *S* como limite superior de *U*, do qual fornecem apenas o limite trivial $100U \leq C$ (*U* é fração; *C*, porcentagem), e a ablação é compatível com o teto sem confirmá-lo. Sem o corretor, *S* está entre 29% e 53%; com ele, entre 48% e 53%, e a variação fica entre −5 e +24 pontos (Figura 3; Flores, 2026). O achado firme é o segundo intervalo: com o corretor, cerca de metade de todas as perguntas recebe uma consulta que compila sem receber nota 4 ou mais (correta ou quase correta). A conversão de erro visível em silencioso é compatível com os dados, que não a demonstram, e somente uma matriz pareada por pergunta a mediria.

Figura 3

Compilação, nota 4 ou mais e faixa de consultas que compilam sem nota 4 ou mais na ablação do SQL Bot



Fonte: Elaboração do autor, com dados da tabela de ablação de Chen et al. (2025).

Nota. Seis das 13 configurações da ablação, com remoções cumulativas: B.1 sem reordenadores, corretor e pesquisador; B.2 sem corretor e pesquisador; B.3 com corretor, sem pesquisador; B.2 e B.3, em laranja-escuro, diferem pela presença do corretor; uma execução por configuração, avaliada pelo juiz gpt-4o. Faixa de (b) pela Equação 4, calculada sobre os percentuais inteiros publicados; indicador aproximado do erro silencioso, que não identifica diretamente *U*, sem supor que toda consulta com nota 4 ou mais compile.

B.2 e B.3 têm o mesmo percentual inteiro publicado de nota 4 ou mais, e o acréscimo posterior do pesquisador moveu compilação e nota em 1 ponto cada; sem repetições nem resultados por pergunta, não se pode estimar a incerteza dessas diferenças, e a queda de 7 pontos entre A.4 e A.5, descrita na seção 2.2, mostra apenas que variações dessa ordem ocorrem entre

configurações vizinhas. Evidências independentes indicam que a fração de erro silencioso é grande. Na análise de erros de um modelo aberto, 98,7% dos erros no BIRD eram semânticos, isto é, passavam pelo compilador (Liu et al., 2025); em estudo piloto, apenas 3% dos SQL incorretos geravam aviso de execução (Hong et al., 2026); e, num estudo de predição seletiva, sinais caixa-preta de autoconsistência separaram respostas certas de erradas com área sob a curva ROC de 0,61 a 0,68, e a execução com retorno de linhas, de 0,50, o nível do acaso, contra 0,82 de um conjunto de juízes de dois provedores (Richardson, 2026). Esses estudos sugerem que a executabilidade isolada discrimina mal a correção; o desempenho preditivo do conjunto de validadores do SQL Bot exigiria avaliação por pergunta, que o caso não publica. Os próprios autores informam que o validador não verifica valores de coluna (Chen et al., 2025), e o erro mais frequente na revisão de especialistas é o filtro incorreto, que, numa leitura do autor sobre a taxonomia de Liu et al. (2025), reúne incompatibilidades de valor, erros de condição e de operador e filtros de data. A coincidência entre a classe não verificada e a categoria de falha mais frequente é compatível com o teto; a desigualdade da Equação 1, por si, não prevê, *a priori*, que o erro silencioso predomine nem qual categoria lidera, e essa predominância é um dado empírico, não uma consequência do modelo.

O erro silencioso tende a ser mais difícil de detectar que o visível porque o usuário recebe uma consulta plausível, acompanhada de verificações visíveis que atestam existência de tabelas e sintaxe, não correção (Chen et al., 2024), e, ao executá-la, pode obter um número plausível, porém incorreto. Para um público declarado de iniciantes em SQL (Chen et al., 2025), esses sinais podem induzir confiança excessiva, hipótese que o caso não testa. O erro também pode realimentar o sistema: popularidade de tabelas e junções comuns derivam de consultas bem-sucedidas nos registros (Chen et al., 2024), e consultas que executam com resposta errada são

indistinguíveis das corretas nesse sinal. Há, ainda, limite de evidência no juiz: ele é o mesmo gpt-4o que gera as consultas, configuração em que avaliadores reconhecem e favorecem as próprias gerações (Panickssery et al., 2024); se presente, esse viés superestimaria Q, e corrigi-lo, mantida a compilação, não reduziria nenhum limite de S na Equação 4 e poderia elevá-los; em B.2 e B.3, pequenas reduções de Q elevam ambos, e o limite inferior calculado é conservador.

Na engenharia de IA, o validador do SQL Bot é um *guardrail*, isto é, uma camada de proteção por regras, e a cobertura de camadas desse tipo é tão completa quanto a antecipação de seus autores (American Global Tech University, 2026, p. 19): elas verificam as propriedades codificadas em suas regras, como a existência de tabelas, e deixam passar o erro que não viola nenhuma delas; o teto é a forma quantitativa dessa limitação, e o compromisso central é o problema clássico de cobertura (Arnold, 1973). As melhorias seguem do teto e se agrupam em quatro frentes, cada uma com sua condição de validade e seu custo. A configuração completa já consome, por pergunta, 4,6 chamadas de modelo, 3 buscas por *embeddings* e 9,4 consultas ao banco, medida que a fonte não define e que não indica leitura de dados, em menos de 60 segundos (Chen et al., 2025), e essa é a linha de base de custo das propostas.

A primeira frente visa reduzir U na origem pela elevação de G: definições aprovadas de métricas, junções e filtros temporais, como o repositório de consultas verificadas do Cortex Analyst (Snowflake, s.d.), restringem o que é gerado. A condição de validade é que as definições tenham dono, versão e aprovação; o custo é a curadoria humana, e o ganho fica restrito às perguntas cobertas pelas definições.

A segunda frente busca elevar d_g sem ler linhas nem executar a consulta em produção. A validação de valores de coluna, deixada pela equipe como trabalho futuro (Chen et al., 2025), pode ser feita, como propõe este estudo, contra os principais valores de cada campo já mantidos

no catálogo, na linha dos verificadores determinísticos com recuperação de valores (Li et al., 2026); como esses valores não formam o domínio completo, a ausência de um valor deve gerar alerta ou pedido de confirmação, não reprovação, e os falsos positivos precisam ser medidos junto com o ganho em d_g. A cardinalidade do filtro pode ser estimada pelas estatísticas do otimizador, que o Trino expõe sobre uma consulta (Trino, s.d.), também como alerta, pois a estimativa é aproximada, pode faltar e uma resposta vazia pode ser correta; é o sinal que o SQLens obtém executando cada comparação (Gong et al., 2025). Por fim, a consulta pode ser executada sobre bancos sintéticos gerados a partir da pergunta e do esquema, sem usar a consulta de referência na geração, que, na avaliação acadêmica, revelam quedas de cerca de 3 a 14 pontos percentuais na acurácia de execução composta, em comparação com a avaliação apenas no banco original (Habibollah & Rafiei, 2026), ideia que a literatura chinesa já discutia ao notar que execuções coincidentes num único banco superestimam o desempenho (Liu et al., 2022). Em produção, o banco sintético só decide se houver um critério de correção, como consultas verificadas, invariantes de negócio ou revisão especializada. Sem acesso aos dados de produção não significa, portanto, sem execução. A comparação determinística com valores já indexados e a consulta a estatísticas existentes podem dispensar novas chamadas de modelo; a geração e a manutenção de bancos sintéticos e a execução das consultas sobre eles têm custo próprio, e abordagens como o SynSQL usam modelos para construir e revisar esses bancos (Habibollah & Rafiei, 2026).

A terceira frente muda o laço: gerar candidatas por caminhos distintos e escolher entre elas por comparação pareada (Pourreza et al., 2025), ou perguntar ao usuário quando a pergunta é ambígua, fronteira em que o GPT-5 completou apenas 8,67% das tarefas conversacionais e

17% das agênticas do BIRD-INTERACT (Huo et al., 2026). O custo é latência e chamadas de modelo adicionais, num sistema cuja velocidade é requisito de implantação.

A quarta frente aceita o teto e mede o que passa: abster-se quando um juiz independente duvida. A abstenção pode elevar a acurácia entre as perguntas respondidas acima de $1 - U$, mas não sobre todas as perguntas, pois o produto de cobertura e acurácia entre as respondidas continua limitado por $1 - U$; o custo é a cobertura, já que responder 27% das perguntas ainda deixou risco seletivo de 24%, isto é, 24% de respostas erradas entre as respondidas, no estudo citado (Richardson, 2026), e amostrar respostas periodicamente para revisão humana, com responsável, cadência e critério de intervenção definidos.

O mesmo raciocínio alcança o fluxo dominante de uso: o “Fix with AI”, responsável por 80% das sessões (Chen et al., 2024), é um corretor acionado por erro de execução real: a consulta de entrada já tem erro visível, e o risco relevante passa a ser o erro que se torna invisível depois do reparo, governado pela taxa de silenciamento e. O teto vale, por fim, para o laço automático: no uso interativo, a execução pelo usuário e suas perguntas de acompanhamento podem recuperar, fora do laço automático, parte do erro silencioso, por acrescentarem informação que o validador não tem (inferência do autor), o que ajuda a explicar a distância entre a satisfação relatada e os 48% do conjunto de avaliação.

3 Considerações Finais

O estudo examinou o SQL Bot do LinkedIn para responder por que um sistema que compila 96% das consultas entrega como corretas ou quase corretas apenas 48% das perguntas. Diante do desafio de achar a fonte autoritativa entre milhões de tabelas, a solução é tecnicamente adequada e coerente com o objetivo de democratizar o acesso a dados: recuperação personalizada pelo organograma e pelo histórico de acesso, grafo de conhecimento alimentado pelo DataHub e pelos usuários, orquestração por intenção e correção com retorno à recuperação, sob as listas de controle de acesso já existentes. A adoção e a satisfação relatadas sugerem utilidade percebida e alinhamento com o objetivo de reduzir a dependência da equipe de dados, benefício que as fontes não quantificam diretamente, e a arquitetura, mais próxima de um fluxo com laço de verificação do que de agentes autônomos, deposita a proteção principal, *de facto*, no controle de acesso do banco, não no modelo.

O principal achado (*insight*) é estrutural. A autocorreção guiada por validador conserta o que o validador enxerga: na ablação publicada, o acréscimo do corretor (B.2 para B.3) elevou a compilação de 76% para 95% sem ganho na fração com nota 4 ou mais, de 47%, e, com o corretor, entre 48% e 53% das perguntas recebem uma consulta que compila sem receber nota 4 ou mais. A proposição do teto organiza essa evidência: um corretor acionado pelo validador não ultrapassa 100% menos a fração de perguntas cuja consulta inicial errada ele não sinaliza. Elevar o teto exige reduzir essa fração, por contexto governado, validação semântica sem leitura de linhas dos dados de produção, como estatísticas do catálogo ou execução em bancos sintéticos, e interação com o usuário quando a pergunta é ambígua; melhorar o corretor ainda pode render ganhos abaixo do teto, que a ablação não quantifica.

As conclusões têm limitações explícitas. Todas as métricas do caso são autorrelatadas, sem replicação independente; a ablação tem uma execução por configuração, sem intervalo de confiança, avaliada por juiz idêntico ao modelo gerador; o conjunto de avaliação não é público; e a nota 4 ou mais aproxima a acurácia de forma imperfeita. A Equação 1 decorre da própria definição de U; o conteúdo do modelo está na decomposição por estágio (Equação 2), na dinâmica de conserto (Equação 3), verificada por simulação, e na delimitação pelos totais (Equação 4). A ablação é compatível com o teto, mas não o confirma, e os dados agregados admitem tanto a conversão de erro visível em silencioso quanto correções compensadas por regressões. As propostas de segurança, governança e telemetria são do autor, não da organização. Quanto aos objetivos específicos, a separação entre fato documentado e proposta, a análise da recuperação, da orquestração, da segurança, da governança e da avaliação e a formalização do teto foram cumpridas.

Para organizações com restrições semelhantes, os resultados sugerem testar, entre as próximas melhorias dos agentes de dados corporativos, a verificação semântica viável sob as restrições de acesso de cada empresa e comparar seu ganho, custo e latência com os de melhorias na geração de SQL. Organizações que avaliam assistentes semelhantes deveriam exigir, além da taxa de compilação e da satisfação dos usuários, a fração de respostas que compilam e estão erradas, porque essa fração pode chegar às decisões sem um erro de compilação que a denuncie, caso as etapas posteriores não a identifiquem. Do ponto de vista da governança, a experiência do caso reforça que o menor privilégio no banco e a separação entre quem pergunta e o que pode ser lido são controles mais confiáveis do que qualquer instrução dada ao modelo.

Como trabalhos futuros, propõem-se: (i) repetir a ablação com várias execuções e matriz de transição pareada por pergunta, que registre, antes e depois do corretor, se a consulta foi

sinalizada pelo conjunto de validadores e se está correta segundo referência independente, para medir diretamente a conversão de erro visível em silencioso; (ii) medir a detectabilidade de cada validador por classe de erro; (iii) medir quanto a checagem de valores de filtro e a execução em bancos sintéticos alteram a detectabilidade, a fração inicial não sinalizada e o erro final; e (iv) comparar juízes de famílias distintas.

Referências

Acharya, D. B., Kuppan, K., & Divya, B. (2025). Agentic AI: Autonomous intelligence for complex goals—A comprehensive survey. *IEEE Access, 13*, 18912–18936. https://doi.org/10.1109/ACCESS.2025.3532853

Ahlawat, G., Chen, A., & Bundele, M. (2024, 11–12 de dezembro). *Empowering self-serve data analytics with a text-to-SQL assistant at LinkedIn* [Apresentação em conferência]. Trino Summit 2024, on-line. https://trino.io/assets/blog/trino-summit-2024/trino-summit-2024-linkedin-ai.pdf

American Global Tech University. (2026). *Engenharia de inteligência artificial: Manual acadêmico e avançado de engenharia de IA* [Material didático da disciplina MIT 509].

Arnold, T. F. (1973). The concept of coverage and its effect on the reliability model of a repairable system. *IEEE Transactions on Computers, C-22*(3), 251–254. https://doi.org/10.1109/T-C.1973.223703

Autio, C., Schwartz, R., Dunietz, J., Jain, S., Stanley, M., Tabassi, E., Hall, P., & Roberts, K. (2024). *Artificial intelligence risk management framework: Generative artificial intelligence profile* (NIST AI 600-1). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.AI.600-1

Chen, A., Bundele, M., Ahlawat, G., Stetz, P., Wang, Z., Fei, Q., Jung, D., Chu, A., Jayaraman, B., Panth, A., Arora, Y., Jain, S., Varma, R., Ilin, A., Melnychuk, I., Chueh, C., Sil, J., & Wang, X. (2024, 9 de dezembro). *Practical text-to-SQL for data analytics*. LinkedIn Engineering Blog. https://www.linkedin.com/blog/engineering/ai/practical-text-to-sql-for-data-analytics

Chen, A., Bundele, M., Ahlawat, G., Stetz, P., Wang, Z., Fei, Q., Jung, D., Chu, A., Jayaraman, B., Panth, A., Arora, Y., Jain, S., Varma, R., Ilin, A., Melnychuk, I., Chueh, C., Sil, J., & Wang, X. (2025). *Text-to-SQL for enterprise data analytics* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2507.14372

Floratou, A., Psallidas, F., Zhao, F., Deep, S., Hagleither, G., Tan, W., Cahoon, J., Alotaibi, R., Henkel, J., Singla, A., van Grootel, A., Chow, B., Deng, K., Lin, K., Campos, M., Emani, V., Pandit, V., Shnayder, V., Wang, W., & Curino, C. (2024). NL2SQL is a solved problem… Not! In *Proceedings of the 14th Annual Conference on Innovative Data Systems Research (CIDR 2024)*. https://www.cidrdb.org/cidr2024/papers/p74-floratou.pdf

Flores, C. U. (2026). *The self-correction ceiling: What a deterministic validator cannot see in multi-agent text-to-SQL* (Version 0.1.0) [Software]. GitHub. https://github.com/ulissesflores/self-correction-ceiling https://doi.org/10.5281/zenodo.24041990

Ghosh, R. (2025). *PREreview of "Text-to-SQL for Enterprise Data Analytics"*. Zenodo. https://doi.org/10.5281/zenodo.17925122

Gong, Y., Lei, C., Qin, X., Vaidya, K., Narayanaswamy, B., & Kraska, T. (2025). SQLens: An end-to-end framework for error detection and correction in text-to-SQL. *Advances in Neural Information Processing Systems, 38*, 150322–150355. https://doi.org/10.52202/085713-4526

Habibollah, M., & Rafiei, D. (2026). *SynSQL: Synthesizing relational databases for robust evaluation of text-to-SQL systems* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2604.27261

Hong, Z., Chen, H., Yuan, Z., Zhang, Q., Zhuang, L., Liao, Q., Huang, F., Song, Y., & Huang, X. (2026). ErrorLLM: Modeling SQL errors for text-to-SQL refinement. In *Proceedings of the 32nd ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2* (pp. 1710–1721). ACM. https://doi.org/10.1145/3770855.3818164

Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). Large language models cannot self-correct reasoning yet. In *The Twelfth International Conference on Learning Representations (ICLR 2024)*. https://openreview.net/forum?id=IkmD3fKBPQ

Huang, R. (2024, 29 de agosto). *Snowflake Cortex Analyst: Evaluating text-to-SQL accuracy for real-world business intelligence scenarios*. Snowflake Engineering Blog. https://www.snowflake.com/en/blog/engineering/cortex-analyst-text-to-sql-accuracy-bi/

Huo, N., Xu, X., Li, J., Jacobsson, P., Lin, S., Qin, B., Hui, B., Li, X., Qu, G., Si, S., Han, L., Alexander, E., Zhu, X., Qin, R., Yu, R., Jin, Y., Zhou, F., Zhong, W., Chen, Y., . . . Cheng, R. (2026). BIRD-INTERACT: Re-imagining text-to-SQL evaluation via lens of dynamic interactions. In *The Fourteenth International Conference on Learning Representations (ICLR 2026)*. https://openreview.net/forum?id=nHrYBGujps

Johnson, J., Busch, C., Khune, A., & Chakka, P. (2024, 19 de setembro). *QueryGPT – Natural language to SQL using generative AI*. Uber Engineering Blog. https://www.uber.com/blog/query-gpt/

Joint Task Force. (2020). *Security and privacy controls for information systems and organizations* (NIST Special Publication 800-53, Rev. 5). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.800-53r5

Kamoi, R., Zhang, Y., Zhang, N., Han, J., & Zhang, R. (2024). When can LLMs actually correct their own mistakes? A critical survey of self-correction of LLMs. *Transactions of the Association for Computational Linguistics, 12*, 1417–1440. https://doi.org/10.1162/tacl_a_00713

LangChain. (s.d.). *LangGraph overview*. LangChain Docs. Recuperado em 7 de novembro de 2026, de https://docs.langchain.com/oss/python/langgraph/overview

Lei, F., Chen, J., Ye, Y., Cao, R., Shin, D., Su, H., Suo, Z., Gao, H., Hu, W., Yin, P., Zhong, V., Xiong, C., Sun, R., Liu, Q., Wang, S. I., & Yu, T. (2025). Spider 2.0: Evaluating language models on real-world enterprise text-to-SQL workflows. In *The Thirteenth International Conference on Learning Representations (ICLR 2025)*. https://openreview.net/forum?id=XmProj9cPs

Lei n. 13.709, de 14 de agosto de 2018. (2018). *Lei Geral de Proteção de Dados Pessoais (LGPD)*. Presidência da República. https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm

Li, B., Chen, C., Xue, Z., Mei, Y., & Luo, Y. (2026). DeepEye-SQL: A software-engineering-inspired text-to-SQL framework. *Proceedings of the ACM on Management of Data, 4*(3), Article 158. https://doi.org/10.1145/3802035

Liu, X., Shen, S., Li, B., Tang, N., & Luo, Y. (2025). NL2SQL-BUGs: A benchmark for detecting semantic errors in NL2SQL translation. In *Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.2* (pp. 5662–5673). ACM. https://doi.org/10.1145/3711896.3737427

Liu, X., Shu, Q., He, J., Wan, C., & Liu, D. (2022). Jiyu ziran yuyan de shujuku chaxun shengcheng yanjiu zongshu [Revisão de pesquisas sobre geração de consultas a bancos de

dados baseada em linguagem natural]. *Ruanjian Xuebao [Journal of Software], 33*(11), 4107–4136. https://doi.org/10.13328/j.cnki.jos.006539

Maamari, K., Abubaker, F., Jaroslawicz, D., & Mhedhbi, A. (2024). The death of schema linking? Text-to-SQL in the age of well-reasoned language models. In *Table Representation Learning Workshop at NeurIPS 2024*. https://openreview.net/forum?id =fglyh5pa7d

Manski, C. F. (2003). *Partial identification of probability distributions*. Springer. https://doi.org /10.1007/b97478

Microsoft. (2026, 18 de maio). *Data, privacy, and security for Foundry Models sold by Azure in Microsoft Foundry*. Microsoft Learn. Recuperado em 7 de novembro de 2026, de https://learn.microsoft.com/en-us/azure/foundry/responsible-ai/openai/data-privacy

National Institute of Standards and Technology. (2023). *CVE-2023-36189* [Registro na National Vulnerability Database]. https://nvd.nist.gov/vuln/detail/CVE-2023-36189

OWASP Gen AI Security Project. (2024). *OWASP top 10 for LLM applications 2025*. OWASP Foundation. https://genai.owasp.org/resource/owasp-top-10-for-llm-applications-2025/

Panickssery, A., Bowman, S. R., & Feng, S. (2024). LLM evaluators recognize and favor their own generations. *Advances in Neural Information Processing Systems, 37*, 68772–68802. https://doi.org/10.52202/079017-2197

Pedro, R., Coimbra, M. E., Castro, D., Carreira, P., & Santos, N. (2025). Prompt-to-SQL injections in LLM-integrated web applications: Risks and defenses. In *2025 IEEE/ACM 47th International Conference on Software Engineering (ICSE)* (pp. 1768–1780). IEEE. https://doi.org/10.1109/ICSE55347.2025.00007

Pourreza, M., Li, H., Sun, R., Chung, Y., Talaei, S., Kakkar, G. T., Gan, Y., Saberi, A., Ozcan, F., & Arik, S. Ö. (2025). CHASE-SQL: Multi-path reasoning and preference optimized candidate selection in text-to-SQL. In *The Thirteenth International Conference on Learning Representations (ICLR 2025)*. https://proceedings.iclr.cc/paper_files/paper/2025/hash/974ff7b5bf08dbf9400b5d599a39c77f-Abstract-Conference.html

Reitich, F. (2026). *Correction and corruption: A two-rate view of error flow in LLM protocols* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2604.18245

Richardson, R. (2026). *What predicts correctness in text-to-SQL? A selective-prediction study* [Preprint]. arXiv. https://doi.org/10.48550/arXiv.2607.06799

Saltzer, J. H., & Schroeder, M. D. (1975). The protection of information in computer systems. *Proceedings of the IEEE, 63*(9), 1278–1308. https://doi.org/10.1109/PROC.1975.9939

Schluntz, E., & Zhang, B. (2024, 19 de dezembro). *Building effective agents*. Anthropic. https://www.anthropic.com/engineering/building-effective-agents

Shen, J., Wan, C., Qiao, R., Zou, J., Xu, H., Shao, Y., Zhang, Y., Miao, W., & Pu, G. (2026). Understanding, detecting, and repairing real-world in-context-learning-based text-to-SQL errors. *Proceedings of the ACM on Software Engineering, 3*(FSE), 3722–3745. https://doi.org/10.1145/3808171

Snowflake. (s.d.). *Verified Query Repository*. Snowflake Documentation. Recuperado em 7 de novembro de 2026, de https://docs.snowflake.com/en/user-guide/views-semantic/verified-query-repository

Song, Y., Zhang, H., Eisenach, C., Kakade, S., Foster, D., & Ghai, U. (2025). Mind the gap: Examining the self-improvement capabilities of large language models. In *The Thirteenth*

International Conference on Learning Representations (ICLR 2025). https://openreview.net/forum?id=mtJSMcF3ek

Spider 2.0. (s.d.). *Spider 2.0 leaderboard*. Recuperado em 7 de novembro de 2026, de https://spider2-sql.github.io/

Stroebl, B., Kapoor, S., & Narayanan, A. (2024). *Inference scaling fLaws: The limits of LLM resampling with imperfect verifiers* (Versão 1) [Preprint]. arXiv. https://arxiv.org/abs/2411.17501v1

Trino. (s.d.). *SHOW STATS*. Trino Documentation. Recuperado em 7 de novembro de 2026, de https://trino.io/docs/current/sql/show-stats.html

Trino. (2024, 17 de dezembro). *Empowering self-serve data analytics with a text-to-SQL assistant at LinkedIn* [Vídeo]. YouTube. https://www.youtube.com/watch?v=rl4GLNEVkjo

Workshop on Agentic AI for Enterprise. (2025). *Call for papers* [Página do evento]. KDD 2025. Recuperado em 7 de novembro de 2026, de https://sites.google.com/view/kddworkshop2025-agentic-ai/call-for-papers

Yang, Z., Zhang, Y., Wang, Y., Xu, Z., Lin, J., & Sui, Z. (2025). A probabilistic inference scaling theory for LLM self-correction. In C. Christodoulopoulos, T. Chakraborty, C. Rose, & V. Peng (Eds.), *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (pp. 13573–13587). Association for Computational Linguistics. https://doi.org/10.18653/v1/2025.emnlp-main.685

Zhong, Y., & Cai, F. (2025, 29 de junho). *Cong 0 dao 1 chaijie FreeWheel ChatBI: Da moxing ruhe chongsu shipin guanggao zhineng shuju fenxi xin shengtai* [Desmontando o ChatBI da FreeWheel do zero: como grandes modelos remodelam a análise de dados de

publicidade em vídeo]. InfoQ China. https://www.infoq.cn/article

/zN5FV8qXONCYTIAuMGLO